

Motivation von Gaußprozessen nach der Residualanalyse

Dieses Skript führt die Residualanalyse nicht erneut durch.  
Es baut auf den Ergebnissen aus Residualanalyse.R auf.

Ausgangspunkt:

Das GAM liefert eine Vorhersage  $\hat{tf}$ .

Die Residualanalyse untersucht  $\epsilon = tf - \hat{tf}$ .

Logik für die Bachelorarbeit:

Wenn  $\epsilon$  noch räumlich, zeitlich oder kovariatenabhängig strukturiert ist,  
dann ist  $\epsilon$  nicht nur zufälliges Rauschen.

Genau dafür sind Gaußprozesse geeignet:

Sie modellieren unbekannte glatte Funktionen über Kovariaten, Raum und Zeit.

Konzeptionelles Folgemodell:

$$tf(s,t) = f_{\text{GAM}}(x(s,t)) + g_{\text{GP}}(x(s,t), s, t) + \epsilon$$

Dabei beschreibt  $f_{\text{GAM}}$  den Haupteffekt und  $g_{\text{GP}}$  die korrelierte Reststruktur.

Verwendete Objekte aus Residualanalyse.R:

df\_val\$resid\_response : Validierungsresiduen  
df\_train\$resid\_response : Trainingsresiduen  
time\_stats : zeitliche Bias-/RMSE-/SD-/MAE-Zusammenfassung  
bias\_df : räumlicher Bias pro Gitterzelle  
rmse\_df : räumlicher RMSE pro Gitterzelle  
sd\_df : räumliche Residualstreuung  
acf\_lag1 : temporale Autokorrelation Lag 1

Damit wird keine zweite Residualanalyse erstellt, sondern nur eine argumentative Zusammenfassung fuer den Uebergang zum Gaußprozess.

## Zentrale Kennzahlen aus der Residualanalyse


Globaler Bias: +0.00015  
Globaler RMSE: 0.13741  
Globaler MAE: 0.08330  
SD der Residuen: 0.13742

ACF Lag 1 zeitlicher Bias: +0.86917  
SD zeitlicher Bias: 0.01801  
SD zeitlicher RMSE: 0.00310

Max. |raeumlicher Bias|: 0.57488  
Mittlerer raeumlicher RMSE: 0.09511  
Max. raeumlicher RMSE: 0.57563  
Mittlere raeumliche SD: 0.06418


## Hinweise auf nicht-zufaellige Reststruktur

Groessere Werte sprechen eher fuer eine GP-Residualmodellierung.



# Kovariaten–Hinweise aus vorhandenen Residuen

Dies ersetzt nicht die Residualplots, sondern fasst sie fuer die GP–Motivation zusammen.



Interpretation: Welche GP-Struktur wäre sinnvoll?

1) Räumliche Reststruktur

Wenn `bias_df` oder `rmse_df` räumliche Cluster zeigen, dann könnte ein räumlicher Kernel `k_space((lon,lat), (lon',lat'))` sinnvoll sein.

2) Zeitliche Reststruktur

Wenn `time_stats` einen glatten Verlauf oder `acf_lag1` eine Autokorrelation zeigt, dann könnte ein zeitlicher Kernel `k_time(t,t')` sinnvoll sein.

3) Kovariatenabhängige Reststruktur

Wenn Residuen noch mit `precip`, `tcold`, `twarm` oder `co2` zusammenhängen, dann könnte ein Kernel auf den Klimakovariaten sinnvoll sein.

4) Kombination

Ein Produkt- oder Summenkernel kann Raum, Zeit und Klima verbinden:

$$k = k_{\text{climate}} + k_{\text{space}} + k_{\text{time}}$$


oder

$$k = k_{\text{climate}} * k_{\text{space}} * k_{\text{time}}$$

In der Bachelorarbeit kann man den GP daher als Residualmodell motivieren, nicht als Ersatz für das GAM.


# Kleine Demo: GP als Residualkorrektur

Nur Stichprobe, Methode: fields::Krig



# Vom GP gelernte Residualkorrektur

Wenn diese Korrektur systematisch von 0 abweicht, steckt Reststruktur in den Residuen.





Moegliche Formulierung fuer die Bachelorarbeit:

Die Residualanalyse des GAM deutet darauf hin, ob die Fehler nach der Anpassung rein zufaellig sind oder noch systematische Struktur enthalten. Insbesondere raeumliche Unterschiede im Bias bzw. RMSE, zeitliche Autokorrelation der gemittelten Residuen oder ein Zusammenhang der Residuen mit Kovariaten wie Niederschlag, Temperatur oder CO<sub>2</sub> sprechen dafuer, dass die vom GAM nicht erklarte Komponente nicht unabhaengig und identisch verteilt ist.

Ein Gaußprozess ist fuer diese Situation eine geeignete Erweiterung, weil er eine unbekannte glatte Restfunktion modelliert und Aehnlichkeiten zwischen Beobachtungen ueber eine Kovarianzfunktion beschreibt. Dadurch kann ein GP als Residualmodell verwendet werden, das raeumliche, zeitliche und kovariatenabhaengige Reststruktur nach dem GAM auffaengt.

Konzeptionell ergibt sich:

$$tf(s,t) = f\_GAM(x(s,t)) + g\_GP(x(s,t), s, t) + \epsilon.$$

Dabei beschreibt  $f\_GAM$  den durch die Kovariaten erklarten grossskaligen Trend, waehrend  $g\_GP$  die korrelierte Reststruktur der Residuen modelliert.