

Motivation von Gaußprozessen mit Variogrammen

Dieses Skript baut auf Residualanalyse.R auf.

Es berechnet keine zweite komplette Residualanalyse, sondern nutzt die vorhandenen Residuen.

Grundidee:

Nach dem GAM betrachten wir die Residuen $r = tf - \hat{tf}_{GAM}$.

Sind nahe Punkte in Raum, Zeit oder Klimaraum residual-ähnlicher als entfernte Punkte, dann sind die Residuen nicht unabhängiges Rauschen.

Das empirische Semivariogramm misst genau das:

$$\gamma(h) = 1/2 * E[(r(u) - r(u+h))^2].$$

Typisches GP-Argument:

Wenn $\gamma(h)$ für kleine Distanzen klein ist und mit h ansteigt, dann gibt es Korrelation/Struktur, die über einen GP-Kernel modelliert werden kann.

Konzeptionell:

$$tf(s,t) = f_{GAM}(x(s,t)) + g_{GP}(x(s,t), s, t) + \epsilon.$$


Kennzahlen aus den vorhandenen Residuen

Globaler Bias: +0.00015
Globaler RMSE: 0.13741
Globaler MAE: 0.08330
SD der Residuen: 0.13742
ACF Lag 1 zeitlicher Bias: +0.86917

Heuristische Variogramm-Reichweiten:
Räumlicher Bias, lon/lat: 226.544
Räumliche Rohresiduen: 271.322
Zeitlicher Bias: 15438.257
Klimaraum: 1.847


Räumliches Semivariogramm des mittleren Residual-Bias

Basis: bias_df aus Residualanalyse.R, also mittlere Residuen pro Gitterzelle




Räumliches Semivariogramm der Validierungsresiduen

Basis: Stichprobe aus df_val\$resid_response, n <= 6000




Zeitliches Semivariogramm der gemittelten Residuen

Basis: time_stats\$mean_resid aus Residualanalyse.R



Semivariogramm im standardisierten Klimaraum

Kovariaten: precip, tcold, twarm, co2



Interpretation der Variogramme

1) Räumliches Variogramm

Ein ansteigendes Semivariogramm bedeutet:
nahe Gitterzellen haben ähnlichere Residuen als entfernte Gitterzellen.
Das motiviert einen räumlichen GP-Kernel:
 $k_{\text{space}}((\text{lon}, \text{lat}), (\text{lon}', \text{lat}'))$.

2) Zeitliches Variogramm

Wenn die Semivarianz mit zeitlicher Distanz steigt,
dann besitzen die Residuen zeitliche Persistenz.
Das motiviert einen zeitlichen GP-Kernel:
 $k_{\text{time}}(t, t')$.

3) Klimaraum-Variogramm

Wenn Residuen bei ähnlichem Klima ähnlicher sind,
dann hat das GAM im Prädiktorraum noch Reststruktur gelassen.
Das motiviert einen Kernel auf precip, tcold, twarm und ggf. co2:
 $k_{\text{climate}}(x, x')$.

Mögliche Kombination:

$$k = k_{\text{space}} + k_{\text{time}} + k_{\text{climate}}$$

oder bei Interaktionen:

$$k = k_{\text{space}} * k_{\text{time}} + k_{\text{climate}}.$$

Mögliche Formulierung für die Bachelorarbeit:

Nach der Anpassung des GAM werden die Validierungsresiduen untersucht. Neben klassischen Residualdiagnostiken kann ein empirisches Semivariogramm verwendet werden, um räumliche, zeitliche oder kovariatenabhängige Reststruktur sichtbar zu machen. Das Semivariogramm beschreibt, wie stark sich zwei Residuen im Mittel unterscheiden, wenn der Abstand zwischen den zugehörigen Punkten wächst.

Ein ansteigendes Semivariogramm ist ein Hinweis darauf, dass nahe Punkte ähnlichere Residuen besitzen als weit entfernte Punkte. Damit sind die Residuen nicht vollständig unabhängig, sondern enthalten eine korrelierte Restkomponente. Diese Situation passt natürlich zur Modellierung mit Gaußprozessen, da Gaußprozesse Abhängigkeiten über eine Kovarianz- beziehungsweise Kernelfunktion beschreiben.

Der Gaußprozess wird daher nicht als Ersatz für das GAM eingeführt, sondern als Residualmodell:

$$tf(s,t) = f_GAM(x(s,t)) + g_GP(x(s,t), s, t) + \epsilon.$$

Dabei beschreibt f_GAM den erklärten Haupteffekt, während g_GP die strukturierte Restkomponente der Residuen modelliert.